

GNN 期末專案 · 財金所

以圖神經網路 預測短影音平台表現

羅頤 · ShortVideo (WWW 2025) · HeteroGNN + GraphSAGE

核心成果

×5.5

排名能力提升倍數
(mean_watch_time)

Spearman 0.256 vs 0.047
(HeteroGNN vs LightGBM)

<https://github.com/roy891030>

研究背景與動機

短影音平台每日新增數十萬支影片

平台需要在影片剛上傳、
無歷史資料條件下即時估計潛在表現，
以決定初始流量分配策略。

這是流量調度、創作者獎勵與
內容生態健康的核心問題。

10,000 匿名使用者

153,561 部影片

6,767,010 條互動記錄

7 天 公開資料期間

侷限一：新上架影片無法預測

傳統協同過濾需影片在訓練集至少出現一次，才能訓練其 embedding。以「前 5 天訓練、後 2 天測試」切分後，21.4% 的測試影片從未在訓練期出現，預測等同隨機猜測。

21.4% 測試影片無歷史資料

侷限二：互動矩陣的極度稀疏

矩陣稀疏度 99.93% 代表即使對已出現的影片，互動記錄也可能只有 1-2 人，統計極不穩定。最優推薦方法 BM3 的 Recall@10 仍僅達 2.38%。

99.93% 使用者－影片矩陣稀疏度

文獻回顧：相關方法與侷限

01

BPR

Rendle et al., UAI 2009

矩陣分解以 BPR 損失最大化正負樣本成對排名，學習使用者與影片的低維 embedding 向量。

✗ embedding 完全從互動記錄學習，新影片停在隨機初始化，預測等同雜訊

02

LightGCN

He et al., SIGIR 2020

簡化 GCN 推薦——移除特徵變換與非線性激活，在使用者-影片二部圖上傳遞高階協同訊號。

✗ 新影片無邊，上架前表現預測問題依然無解

03

MMGCN / BM3

Wei et al. 2019 · Zhou et al. 2023

為視覺、音訊、文字各建使用者-影片圖，以 GCN / 自監督對比學習融合多模態特徵。

✗ 仍依賴使用者互動圖 G_m ，新影片無法有效接入圖結構

04

MMVED / HMMVED

Zhu et al. 2020 · Xie et al. 2021

多模態變分框架預測短影片人氣 (Vine/NUS)，HMMVED 進一步引入層次多任務架構。

✓ 不依賴互動記錄 ✗ 無圖鄰域訊號 (視覺相似鄰居的觀看時長)

05

LightGBM

Ke et al., NeurIPS 2017

梯度提升決策樹以影片自身特徵向量 (R^{819}) 直接回歸 8 個表現指標，本研究的非圖基準模型。

✓ 天然支援無歷史資料情境 ✗ 無法利用跨影片關聯性訊號

★

GraphSAGE (target paper)

Hamilton et al., NeurIPS 2017

歸納學習框架——訓練完成後，對訓練期從未出現的新節點也能產生有意義的 embedding。

✓ 可泛化至新節點，適合上架前情境；本研究擴展為異質版 HeteroGNN

BPR / LightGCN 無法解決冷啟動 → MMGCN / BM3 引入多模態但仍依賴互動圖 → LightGBM 無圖訊號 → 本研究以 GraphSAGE 異質圖填補空缺

現有方法的不足與本研究的定位

方法	上架前預測	全平台指標	不需使用者歷史	圖鄰域訊號	主要侷限
BPR	✗	✗	✗	✗	純互動 embedding，新影片無梯度
LightGCN	✗	✗	✗	△	同質互動二部圖，新影片無邊
MMGCN	△	✗	✗	△	多模態 emb，仍依賴互動圖 G_m
BM3	△	✗	✗	△	自監督對比，主場景仍為推薦
MMVED / HMMVED	✓	✓	✓	✗	多模態人氣預測，無圖鄰域訊號
LightGBM（直接基準）	✓	✓	✓	✗	僅利用影片自身特徵，無跨影片關聯
本研究（HeteroGNN）	✓	✓	✓	✓	唯一同時滿足四個核心需求的方法

✗：不支援 △：部分支援 ✓：完整支援

★ 本研究填補「無歷史資料 + 圖鄰域訊號」的空缺

資料集概覽：ShortVideo (Shang et al., WWW 2025)

核心統計

項目	數值	說明
使用者數	10,000	匿名化，含性別、年齡、城市等 6 種屬性
影片數	153,561	每部有原始 .mp4 及預抽取特徵
互動記錄數	6,767,010	28 欄，含 7 種行為 + 觀看時長
視覺特徵維度	768	ViT-B/16 平均池化 (image_feat.npy)
文字特徵維度	50	SBERT 降維 (text_feat.npy)
矩陣稀疏度	99.93%	僅 0.07% 的使用者－影片格子非空
平均被互動人數	6.6 人	大量影片互動記錄極少

8 個行為指標的稀疏度 (54,088 部有效樣本)


指標	中位數	零值比例
like_rate	0.000	84.6%
comment_rate	0.000	96.7%
follow_rate	0.000	96.9%
collect_rate	0.000	95.2%
forward_rate	0.000	98.0%
hate_rate	0.000	99.2%
effective_view_rate	0.833	1.8%
mean_watch_time ★	22 秒	0.2%

為何選擇 mean_watch_time 為主要目標？

zero 比例僅 0.2%，直接反映觀眾對影片內容的吸引力，是最適合以內容特徵預測的目標。

方法設計：以影片為中心的異質圖

異質圖示意



粉紅節點：無歷史資料的新影片仍可透過 cosine kNN 從視覺相似老影片借用訊號

file:///Users/luoyi/Desktop/shortvideo_mmgcn_poc/docs/hetero_gnn_demo.html

三種節點

節點類型	數量	維度	特徵構成
影片 (video)	54,088	819	768 ViT 視覺 + 50 SBERT 文字 + 1 log 時長
作者 (author)	34,939	10	log 粉絲數 + 作品數 + 8 指標訓練集均值
分類 (category)	51	128	可學習 Embedding, 隨訓練更新

三種邊 (總計 1,159,246 條)

邊類型	連接	邊數	建構方式
similar_to ★	影片 ↔ 影片	942,894	768 維視覺特徵 cosine kNN ($k=10$)
posted_by	影片 → 作者	108,176	從 author_id 欄讀取
belongs_to	影片 → 分類	108,176	從 category_id 欄讀取

similar_to 邊的關鍵：建立此邊僅需視覺特徵，不需互動記錄，新影片也能透過視覺相似性接入圖中，借用鄰近影片的歷史表現訊號。

HeteroGNN 模型架構：三段式設計

輸入層

- video.x [54,088 × 819]
- author.x [34,939 × 10]
- category.emb [51, 128]

輸入投影層 (Linear + ReLU)

- video/author: Linear
- category:
Embedding(51,128)
- → 統一 d = 128 維

HeteroConv Layer 1 (1-hop)

- GraphSAGE 聚合
- 5 種邊關係各自傳遞
- ReLU + Dropout(0.1)

HeteroConv Layer 2 (2-hop)

- 鄰居已融合鄰域資訊
- 感受野擴展到 2-hop
- ReLU + Dropout(0.1)

輸出頭 (video only)

- h[128]
- → Linear(128,64)
- → Linear(64,8)
- → $\hat{y} \in \mathbb{R}^8$

GraphSAGE 異質聚合更新公式（每層）

$$h_v^{(l+1)} = \sigma \left(W_{\text{self}}^{(l)} h_v^{(l)} + \sum_{r \in \mathcal{R}} W_r^{(l)} \cdot \frac{1}{|N_r(v)|} \sum_{u \in N_r(v)} h_u^{(l)} \right)$$

$\mathcal{R}$ = 邊關係集合（5 種） σ = ReLU $W_r^{(l)}$ = 關係 r 專屬可學習投影矩陣 $\in \mathbb{R}^{(128 \times 128)}$

實驗設定：資料切分、訓練配置與損失函數

訓練設定 (Table 7)

項目	設定
資料切分	80/10/10 (訓練 43,270 / 驗證 5,408 / 測試 5,410)
深度學習框架	PyTorch Geometric (PyG)
優化器	Adam, lr = 10^{-3}
訓練 epoch	至多 500, patience = 50
隱藏維度 d	128
Dropout	0.1 (每層 HeteroConv 後)
總參數量	450,632

防止 data leakage 屏障

資料切分後，所有依賴「標籤」的二次特徵（作者歷史均值）僅允許使用訓練集（43,270 部）計算。驗證集與測試集的標籤在整個訓練過程中對模型不可見，直至最終評估時才讀取。

多任務損失函數

8 個預測目標同時訓練，以曝光次數加權：

$$\mathcal{L} = \sum_v w_v \left[\sum_{k=0}^6 (\hat{y}_{v,k} - y_{v,k})^2 + \mathcal{L}_{\text{Huber}}(\hat{y}_{v,7}, \log(1+y_{v,7}); \delta=1) \right]$$

MSE (7 個 rate 指標)

使用均方誤差，均等對待各率類指標。

Huber 損失 (觀看時長)

誤差小時平方懲罰，誤差大時線性，避免 MSE 對離群值（最大 545 秒）過度懲罰。

$\log(1+t)$ 轉換

觀看時長高度右偏（中位數 22 秒，最大 545 秒），對數壓縮使模型對各時長範圍均等學習。

曝光加權 w_v

$w_v = n_v / \sum n_u$ ，曝光多的影片標籤統計更可靠，應予更高的訓練權重。

研究成果：HeteroGNN vs LightGBM

測試集 5,410 部影片


指標	HeteroGNN Spearman ↑	LightGBM Spearman ↑	HeteroGNN MAE ↓	LightGBM MAE ↓
like_rate	-0.032	-0.001	0.058	0.044
comment_rate	+ 0.012	-0.003	0.039	0.009
follow_rate	-0.031	-0.009	0.024	0.008
collect_rate	+ 0.011	-0.035	0.074	0.013
forward_rate	-0.005	-0.012	0.066	0.005
hate_rate	+ 0.019	-0.014	0.029	0.002
effective_view_rate	-0.012	+ 0.016	0.169	0.143
mean_watch_time ★	+ 0.256	+ 0.047	386 秒	24 秒

核心成果

0.256

mean_watch_time Spearman

vs LightGBM: 0.047 → 提升 5.5 倍



核心發現

01

圖結構顯著提升觀看時長的排名預測

mean_watch_time 的 Spearman 相關係數從 0.047 (LightGBM) 提升至 0.256 (HeteroGNN)，提升幅度達 5.5 倍。圖神經網路的訊息傳遞能有效地將「視覺風格相似影片的觀看時長」此一鄰域訊號融合進影片的表示向量中，支持了研究假說。

02

Rate 指標的可預測性受到零膨脹分佈的根本限制

7 個 rate 指標的 Spearman 對兩個模型而言都接近 0。以 like_rate 為例，84.6% 的影片按讚率為零，顯示此類目標存在明顯的零膨脹與長尾分佈。按讚、留言等行為亦易受曝光策略、社群擴散等外部因素影響，現有內容特徵與圖結構均無法完整捕捉這些因素。

03

Spearman 與 MAE 的矛盾揭示模型本質差異

HeteroGNN 的 mean_watch_time MAE 遠高於 LightGBM (386 秒 vs 24 秒)，但 Spearman 遠優 (0.256 vs 0.047)。LightGBM 傾向預測接近平均值的保守估計 (MAE 小但排名無力)；HeteroGNN 排名能力強，但 embedding 尚未精確校準到真實秒數 (排名正確但絕對值偏大)。

結論

1

以影片為中心的異質圖神經網路在無使用者互動歷史的上架前表現預測上，mean_watch_time 的 Spearman 排名相關係數達 0.256，是非圖基準 LightGBM (0.047) 的 5.5 倍，證明圖鄰域訊號的實質效益。

2

similar_to 邊 (cosine kNN) 讓即使沒有互動記錄的新影片也能接入圖中，有效解決冷啟動問題，是本研究能超越基準的關鍵設計。

3

Rate 指標 (按讚、留言等) 受零膨脹分佈根本性限制，值得未來研究針對稀疏二元目標進行專項設。

4

Spearman 高但 MAE 大的矛盾顯示 embedding 尚未校準到真實秒數，未來可引入校準策略，同時保留排名能力並改善數值精確度。

References

[1] Rendle, S. et al. BPR: Bayesian Personalized Ranking from Implicit Feedback. UAI 2009.

[3] Wei, Y. et al. MMGCN: Multi-modal Graph Convolution Network for Personalized Recommendation of Micro-video. ACM MM 2019.

[5] Zhu, Q. et al. Popularity Prediction for Short Video. ICME 2020.

[7] Ke, G. et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. NeurIPS 2017.

[2] He, X. et al. LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation. SIGIR 2020.

[4] Zhou, X. et al. Bootstrap Latent Representations for Multi-Modal Recommendation. WWW 2023.

[6] Xie, Z. et al. Hierarchical Multi-modal Variational Encoder-Decoder for Video Popularity Prediction. ICME 2021.

[8] Hamilton, W.L. et al. Inductive Representation Learning on Large Graphs. NeurIPS 2017.

[9] Shang, H. et al. Short Video Understanding — NineRec Benchmark. WWW 2025.